

Experimento individual de escalabilidad H4.3.1

Reprocesamiento masivo de perfiles / Open Data

Objetivo: evaluar escalamiento vertical y horizontal con carga progresiva hasta 1.400 TPS. Criterios: p95 <= 400 ms, p99 <= 800 ms y errores < 1%.

Implementacion

Se implemento POST /perfilamiento/reprocesar, un escenario k6 de tasa constante, composiciones Docker para ambas tacticas, balanceo Nginx local y GET /health para el balanceador AWS. Todo esta en la rama experimento-escalabilidad-h4-3-1; main no fue modificado.

Entorno AWS

AWS Academy, us-east-1. Tres EC2 t2.medium para la aplicacion en tres zonas, una EC2 para PostgreSQL 16 y Application Load Balancer Cheapest-alb. k6 0.55.0 se ejecuto desde CloudShell durante 15 s por nivel. Commit desplegado: 12bc015.

Riesgo de correspondencia del ASR

El repositorio no contenia el flujo completo de perfilamiento ni un canal en linea. El endpoint agrega una operacion minima y realista sobre PostgreSQL para representar reprocesamiento. Por tanto, los resultados validan la tactica y el arnes experimental, no la capacidad definitiva de una futura logica de negocio completa.

Resultados AWS - escalamiento vertical

CPU / memoria	TPS	Logrados	p95 ms	p99 ms	Errores %	Descartadas
1 / 1 GiB	200	199,88	11,11	57,65	0,000	0
1 / 1 GiB	500	493,56	634,84	1.571,83	0,000	95
1 / 1 GiB	800	799,85	29,56	62,37	0,000	0
1 / 1 GiB	1100	919,85	1.637,24	1.715,96	0,000	1852
1 / 1 GiB	1400	877,55	4.187,90	4.904,78	0,000	6993
2 / 2 GiB	200	199,99	6,32	14,46	0,000	0
2 / 2 GiB	500	499,91	6,72	49,47	0,000	0
2 / 2 GiB	800	799,84	21,20	40,71	0,000	0
2 / 2 GiB	1100	1.001,19	1.019,29	1.431,81	0,000	1096
2 / 2 GiB	1400	965,38	3.064,70	3.236,13	0,000	5675

Con 2 CPU/2 GiB se sostuvo hasta 800 TPS dentro de los criterios. A 1.100 y 1.400 TPS la instancia unica excedio p95/p99 y descarto iteraciones. El t2.medium limita el experimento vertical a 2 vCPU fisicos.

Resultados AWS - escalamiento horizontal

Instancias	CPU / memoria c/u	TPS	Logrados	p95 ms	p99 ms	Errores %	Descartadas
3	1 / 1 GiB	200	199,96	9,54	15,81	0,000	0
3	1 / 1 GiB	500	499,86	8,48	19,30	0,000	0
3	1 / 1 GiB	800	799,59	9,49	30,08	0,000	0
3	1 / 1 GiB	1100	1.099,59	8,25	18,40	0,000	0
3	1 / 1 GiB	1400	1.399,42	9,56	40,65	0,000	0

A 1.400 TPS, tres instancias lograron 1.399,42 TPS, p95 9,56 ms, p99 40,65 ms, 0% de errores y cero descartes. Los tres destinos estaban saludables en el ALB.

Analisis y decision

La hipotesis queda respaldada en AWS: el escalamiento horizontal supera claramente a una sola instancia incluso despues de duplicar sus recursos. Se recomienda horizontal como tactica principal y vertical como ajuste inicial. La tasa maxima equivale aproximadamente a 10,08 millones de perfiles en dos horas si se sostiene.

Limitaciones

Las corridas AWS duraron 15 s para ajustarse al presupuesto academico. Falta una prueba de estabilidad de dos horas, incorporar la logica completa futura y medir simultaneamente el canal en linea cuando exista. PostgreSQL se ejecuto en EC2, no en RDS.

Evidencia y reproduccion

Los valores exactos estan versionados en experiments/h4.3.1/AWS_RESULTADOS.tsv y el procedimiento en experiments/h4.3.1/README.md. Los JSON crudos quedaron en AWS CloudShell como ~/h431-aws-results.tgz. Para el video: mostrar las tres instancias saludables, el ALB, el codigo, ejecutar k6 y presentar las tablas de este informe.